

Acquisition & OCR

Documentation technique — Module GED PLUSSCI

Ce document décrit l'architecture et le fonctionnement du module d'acquisition et d'OCR : canaux d'import (upload, scan, e-mail), pipeline de traitement du texte, classification automatique, formats supportés et configuration opérationnelle.

Acquisition & OCR - Documentation technique

Table des matieres

1. Vue d'ensemble
2. Architecture & flux de donnees
3. Canaux d'acquisition
 - 3.1 Depot manuel (interface web)
 - 3.2 Importation par e-mail (IMAP)
 - 3.3 Dossier de numerisation surveille (scan folder)
4. Pipeline OCR
5. Classification automatique
6. Formats de fichiers acceptes
7. Configuration
8. Commandes Artisan
9. Modele de donnees
10. Controle d'accès
11. Indicateurs & tableau de bord

1. Vue d'ensemble

Le module Acquisition & OCR constitue le point d'entree de tous les documents dans la GED (Gestion Electronique de Documents). Il combine :

- * Trois canaux d'acquisition : depot web, e-mail IMAP, dossier scanner reseau.
- * Un pipeline OCR asynchrone base sur smalot/pdfparser (PDF natif) et Tesseract (images, PDF numerises).
- * Une classification automatique par analyse textuelle qui detecte le type documentaire, extrait les mots-cles et propose un dossier cible.
- * Un panier d'acquisition qui affiche une previsualisation (type detecte, disponibilite OCR, suggestion de classement) avant le transfert definitif vers la GED.

Page Filament : GED > Acquisition & OCR

Classe : App\Filament\Pages\AcquisitionPage

2. Architecture & flux de donnees

```

????????????????????????????????????????????????????????????
?          Canaux d'acquisition                                     ?
?                                                                 ?
? Interface web    ->   AcquisitionPage::save()                   ?
? IMAP             ->   EmailImportService                        ?
? Scan folder     ->   ProcessScanFolderCommand                  ?
????????????????????????????????????????????????????????????
?
v
DocumentImportService::import()
?
????????????????????????????????????????????????????????????
v              v              v
Document      DocumentVersion      Spatie Media
(create)      (version 1.0)         (fichier physique)
?
v
ExtractDocumentTextJob  (queue async)
?
v
OcrService
????????????????????????????????????????
? PDF -> smalot/pdfparser?
? Image -> Tesseract      ?
? TXT -> lecture directe?
????????????????????????????????????????
?
v
ClassifyDocumentJob  (delai 3 s)
?
v
AutoClassificationService::classify()
(type, tags, mots-cles, metadonnees)

```

3. Canaux d'acquisition

3.1 Depot manuel (interface web)

L'opérateur dépose jusqu'à 20 fichiers par lot via l'interface Filament.

Options du formulaire :

Champ	Description	Valeur par défaut
Fichiers	Selection multi-fichiers (glisser-deposer)	-
Dossier cible	Dossier GED de destination	Aucun (non classe)
Type de document	Type documentaire ou Detection automatique	__auto__

Prefixe du titre	Ajoute devant le nom de chaque fichier	Vide
Reconnaissance automatique du type	Active la detection par nom + OCR	v
Classement intelligent	Propose le meilleur dossier cible	v
Confidentialite	Standard / Confidentiel / Personnel	Standard

Taille maximale par fichier : configurable via `ged.max_file_size_mb` (defaut : 50 Mo).

Resolution du type documentaire :

```

si type selectionne ? "__auto__"
  -> utiliser le type selectionne
sinon si auto_detect_type = true
  -> AutoClassificationService::detectType(titre, nom fichier)
  -> si confiance < 50 % -> "Document"
sinon
  -> "Document"

```

Resolution du dossier cible :

```

si dossier_id renseigne manuellement
  -> utiliser ce dossier
sinon si auto_suggest_dossier = true
  -> chercher un dossier actif dont le libelle match le type detecte
sinon
  -> null (document non classe)

```

3.2 Importation par e-mail (IMAP)

Accessible via le bouton << Importer depuis e-mail >> dans la page Acquisition, ou directement via la commande Artisan.

Comportement :

1. Connexion IMAP avec les parametres fournis (ou ceux de la configuration).
2. Recuperation de tous les messages non lus (unseen) dans le dossier IMAP specifie.
3. Pour chaque message : importation de chaque piece jointe comme un Document distinct.
4. Le sujet du message devient le titre du document ; l'expediteur est enregistre dans `source_meta`.
5. Le message est marque lu (Seen) apres traitement.
6. Les messages sans piece jointe sont ignores (comptabilises dans skipped).

Classe : `App\Services\EmailImportService`

Source enregistree : `source = 'email', source_meta = "De: sender | Sujet: subject"`

3.3 Dossier de numérisation surveille (scan folder)

Permet l'intégration avec des scanners réseau ou multifonctions qui déposent des fichiers dans un dossier partagé.

Fonctionnement :

1. Le scanner dépose les fichiers dans le dossier ACQUISITION_SCAN_FOLDER (default : storage/app/scan-inbox).
2. La commande acquisition:process-scan-folder lit ce dossier, importe chaque fichier dans la GED via DocumentImportService, puis déplace le fichier traité vers ACQUISITION_SCAN_DONE_FOLDER (default : storage/app/scan-done).
3. L'interface web affiche en temps réel le contenu du dossier scanner et le nombre de fichiers en attente.

Extensions prises en charge : pdf, jpg, jpeg, png, tiff, tif, bmp, doc, docx, txt

Source enregistrée : source = 'scan_folder'

4. Pipeline OCR

Classe App\Services\OcrService

Méthode extract(string \$filePath, string \$mimeType): array

Retourne ['status' => string, 'text' => string|null, 'error'? => string]

Statut	Signification
completed	Texte extrait avec succès
pending	En attente de traitement
processing	Extraction en cours
failed	Erreur lors de l'extraction
unavailable	Type MIME non supporté ou Tesseract absent

Backends d'extraction

Type de fichier	Backend	Prérequis
PDF avec texte natif	smalot/pdfparser (PHP pur)	Aucun
PDF scanné (image)	Tesseract OCR (fallback)	Binaire Tesseract installé
Image (JPG, PNG, TIFF...)	Tesseract OCR	Binaire Tesseract installé
Texte brut (TXT)	file_get_contents	Aucun

Détection de Tesseract

Le service cherche le binaire dans cet ordre :

1. Variable d'environnement TESSERACT_PATH
2. tesseract (dans le PATH)
3. C:\Program Files\Tesseract-OCR\tesseract.exe
4. C:\Program Files (x86)\Tesseract-OCR\tesseract.exe
5. /usr/bin/tesseract
6. /usr/local/bin/tesseract

Job asynchrone App\Jobs\ExtractDocumentTextJob

- * Déclenchement : automatiquement lors de chaque import, via ExtractDocumentTextJob::dispatch(\$version->id).
- * Tentatives : 2 (\$tries = 2)
- * Timeout : 120 secondes
- * En cas de succès OCR : déclenche ClassifyDocumentJob avec un délai de 3 secondes.
- * En cas d'échec : ocr_status = failed, ocr_text = null.

5. Classification automatique

Classe App\Services\AutoClassificationService

Detection du type (detectType)

Le texte OCR, le titre et le nom de fichier sont analysés via des règles regex pondérées.

Types détectés et poids :

Type documentaire	Poids	Exemples de patterns
Rapport activité	3	rapport d'activité, bilan annuel
Rapport mission	3	rapport de mission, compte-rendu de mission
PV réunion	3	proces-verbal, PV réunion
Compte-rendu	2	compte-rendu, CR réunion
Note de service	2	note de service, N.S. ndeg
Contrat	2	contrat de, convention de, marche
Facture	2	facture ndeg, montant TTC, total HT
Bon de commande	2	bon de commande, BC ndeg
Décision	2	décision ndeg, arrêté ndeg
Procédure	2	procédure de, guide d'utilisation

Courrier entrant	1	ci-joint, j'ai l'honneur, veuillez trouver
Courrier sortant	1	objet :, reference :, a l'attention de

Le type retenu est celui avec le score le plus eleve. La confiance est calculee proportionnellement au score maximum possible (0-100 %).

> Regle de mise a jour : le type du document est remplace par le type auto-detecte uniquement si la confiance est ? 60 % et si le type actuel est Document, Autre ou vide.

Extraction des tags et mots-cles

- * Tokenisation du texte OCR + titre.
- * Suppression des stopwords (listes francaise et anglaise integrees).
- * Conservation des tokens de 3-40 caracteres.
- * Dedoublonnage, tri par frequence, conservation des 30 premiers.

Extraction de metadonnees structurees

Le service recherche et extrait automatiquement :

- * Dates (formats DD/MM/YYYY, YYYY-MM-DD, dates en lettres)
- * References documentaires (numeros de reference)
- * Montants (valeurs numeriques avec indicateurs financiers)

6. Formats de fichiers acceptes

Format	Extension	MIME type	OCR
PDF natif	.pdf	application/pdf	smalot/pdfparser
PDF scanne	.pdf	application/pdf	Tesseract (fallback)
Word (legacy)	.doc	application/msword	-
Word	.docx	application/vnd.openxmlformats-officedocument.wordprocessingml.document	-
Excel (legacy)	.xls	application/vnd.ms-excel	-
Excel	.xlsx	application/vnd.openxmlformats-officedocument.spreadsheetml.sheet	-
Image JPEG	.jpg, .jpeg	image/jpeg	Tesseract
Image PNG	.png	image/png	Tesseract

Image TIFF	.tiff, .tif	image/tiff	Tesseract
Texte brut	.txt	text/plain	Lecture directe

7. Configuration

Fichier config/acquisition.php

Cle	Variable .env	Valeur par défaut	Description
scan_folder	ACQUISITION_SCAN_FOLDER	Storage/app/scan-inbox	Dossier de depot scanner
scan_done_folder	ACQUISITION_SCAN_DONE_FOLDER	Storage/app/scan-done	Dossier d'archivage apres import
tesseract_path	TESSERACT_PATH	`` (auto-detection)	Chemin vers le binaire Tesseract
tesseract_lang	TESSERACT_LANG	fra+eng	Langues OCR (codes Tesseract)
imap.host	IMAP_HOST	``	Serveur IMAP
imap.port	IMAP_PORT	993	Port IMAP
imap.encryption	IMAP_ENCRYPTION	ssl	Chiffrement (ssl, tls, vide)
imap.validate_cert	IMAP_VALIDATE_CERT	false	Validation du certificat SSL
imap.username	IMAP_USERNAME	``	Adresse e-mail
imap.password	IMAP_PASSWORD	``	Mot de passe
imap.folder	IMAP_FOLDER	INBOX	Dossier IMAP a surveiller
imap.protocol	IMAP_PROTOCOL	imap	Protocole (imap, pop3)
max_file_size_mb	ACQUISITION_MAX_FILE_SIZE	50	Taille maximale par fichier (Mo)

Exemple .env

```
# --- Acquisition & OCR ---

# Dossiers scanner
ACQUISITION_SCAN_FOLDER=/var/scan/inbox
ACQUISITION_SCAN_DONE_FOLDER=/var/scan/done

# Tesseract OCR
TESSERACT_PATH=/usr/bin/tesseract
TESSERACT_LANG=fra+eng

# Import e-mail IMAP
IMAP_HOST=imap.example.com
IMAP_PORT=993
IMAP_ENCRYPTION=ssl
IMAP_VALIDATE_CERT=false
IMAP_USERNAME=ged@example.com
IMAP_PASSWORD=secret
IMAP_FOLDER=INBOX

# Limite de taille
ACQUISITION_MAX_FILE_MB=50
```

Parametre GED persistant

La taille maximale peut aussi etre surchargee depuis les parametres applicatifs (app_settings) via la cle ged.max_file_size_mb, qui prend la priorite sur la valeur .env.

8. Commandes Artisan

acquisition:process-scan-folder

Importe les fichiers presents dans le dossier scanner.

```
php artisan acquisition:process-scan-folder [options]
```

Option	Description
--dossier=<id>	ID du dossier GED cible (optionnel)
--folder=<path>	Chemin du dossier de scan (ecrase ACQUISITION_SCAN_FOLDER)
--dry-run	Liste les fichiers sans les importer

Exemple :

```
# Import reel dans le dossier GED #5
php artisan acquisition:process-scan-folder --dossier=5

# Simulation sans import
php artisan acquisition:process-scan-folder --dry-run

# Dossier personnalis  
php artisan acquisition:process-scan-folder --folder=/mnt/scanner/hp-mfp
```

acquisition:import-emails

Importe les pi  ces jointes des e-mails non lus depuis une boite IMAP.

```
php artisan acquisition:import-emails [options]
```

Option	Description
--dossier=<id>	ID du dossier GED cible (optionnel)
--host=<hostname>	Serveur IMAP (ecrase IMAP_HOST)
--port=<port>	Port IMAP (default : 993)
--username=<email>	Adresse e-mail
--password=<pwd>	Mot de passe
--folder=<folder>	Dossier IMAP (default : INBOX)
--dry-run	Test de connexion sans import

Exemple :

```
# Import depuis la configuration .env
php artisan acquisition:import-emails

# Import vers le dossier GED #3, boite explicite
php artisan acquisition:import-emails --dossier=3 --host=imap.gmail.com --username=ged@example.com --password=

# Test de connexion uniquement
php artisan acquisition:import-emails --dry-run
```

Planification recommand  e (Scheduler)

Ajouter dans routes/console.php ou App\Console\Kernel :

```
// Import scanner toutes les 5 minutes
Schedule::command('acquisition:process-scan-folder')->everyFiveMinutes();

// Import e-mails toutes les 15 minutes
Schedule::command('acquisition:import-emails')->everyFifteenMinutes();
```

9. Modele de donnees

Document

Colonne	Type	Description
reference_doc	string	Reference unique auto-generee
titre	string	Titre du document
type_document	string	Type documentaire
dossier_id	FK	Dossier GED parent
auteur_id	FK	Utilisateur createur
etat_cycle_vie	string	Brouillon, Valide, Archive...
confidentiality_level	string	Standard, Confidentiel, Personnel
version_courante_id	FK	Derniere version active
tags_json	JSON	Liste de tags extraits
keywords	text	Mots-cles concatenes
metadata_json	JSON	Metadonnees structurees extraites
classification_confidence	int	Score de confiance (0-100)
classified_at	datetime	Date de derniere classification

DocumentVersion

Colonne	Type	Description
document_id	FK	Document parent
numero_version	string	Ex : 1.0, 1.1, 2.0
media_id	FK	Fichier physique (Spatie Media)
ocr_status	string	pending / processing / completed / failed / unavailable
ocr_text	longtext	Texte extrait par OCR

checksum_sha256	string	Empreinte SHA-256 du fichier
source	string	upload, email, scan_folder
source_meta	string	Metadonnee contextuelle (chemin, expediteur...)

10. Controle d'accès

L'accès à la page Acquisition & OCR est contrôlé par la méthode `canAccess()` :

```
// App\Filament\Pages\AcquisitionPage
public static function canAccess(): bool
{
    return $user->hasRole('Super Admin')
        || $user->hasPermissionTo('ged.documents.create');
}
```

Permission requise : `ged.documents.create`

Cette permission est associée au groupe GED dans la matrice des rôles. Tout rôle disposant de cette permission peut accéder au module d'acquisition.

11. Indicateurs & tableau de bord

La page Acquisition affiche quatre compteurs en temps réel :

Indicateur	Description
OCR en attente	DocumentVersion avec <code>ocr_status = 'pending'</code>
OCR termine	DocumentVersion avec <code>ocr_status = 'completed'</code>
Scan inbox	Nombre de fichiers présents dans <code>ACQUISITION_SCAN_FOLDER</code>
OCR en cours	DocumentVersion avec <code>ocr_status = 'processing'</code>

Ces valeurs sont calculées côté serveur dans la propriété calculée `acquisitionStats` de `AcquisitionPage` et rafraîchies à chaque rendu Livewire.

Installation de Tesseract (Windows)

1. Télécharger l'installateur depuis : <https://github.com/UB-Mannheim/tesseract/wiki>
 2. Installer en incluant le pack de langue French (fra) lors de l'installation.
 3. Ajouter le répertoire d'installation au PATH système, ou renseigner le chemin complet dans `.env` :
- ```
`dotenv`
```